

Modelos de Regressão

Previsão de preços de reservas em alojamentos Airbnb

Relatório de Projeto

TRABALHO REALIZADO POR:

DANIEL FONSECA | 125158 | CD-PL-B1

DANIIL SAMSONYUK | 130646 | CD-PL-B1

GUILHERME PIRES | 131658 | CD-PL-B1

JOÃO FILIPE | 130665 | CD-PL-B1

DOCENTES:

Maria da Conceição Torres Figueiredo

António Carlos Simões

Índice

1. Introdução	2
1.1 Business Understanding	2
1.2 Definição do Problema	2
2. Data Understanding	3
2.1 Estrutura do Dataset listings.csv	3
2.2 Limpeza dos dados	3
2.3 Pré-Processamento e Feature Engineering	5
3. Estatísticas Descritivas	7
3.1 Preço por Tipo de Alojamento	7
3.2 Preço por Bairro	8
3.3 Variáveis Numéricas	9
4. Análise de correlação e causalidade	9
4.1. Redundância nas Variáveis Review (Multicolinearidade)	10
4.2. Correlação Entre as Variáveis	10
5. Modelagem	10
5.1 Divisão em Treino e Teste	10
5.2 Modelo 1 - Regressão Linear Simples	11
5.3 Modelo 2 - Regressão Linear Múltipla	12
5.4 Modelo 3 - Regressão Polinomial	12
5.5 Modelo 4 - Regressão Não Linear com Log nos preditores	13
5.6 Modelo 5 - Regressão Linear com Interação	14
5.6 Modelo 6 - Tentativa com Coordenadas Geográficas	15
5.7 Escolha do Modelo	15
5.8 Teste de Chow	16
6. Avaliação de Performance	17
6.1 Métricas e resultados do Modelo 4 no conjunto de teste	17
6.2 Análise de Resultados Graficamente	18
Real vs Previsto por Tipo de Alojamento	18
Resíduo Médio por Bairro (Conjunto de Teste)	19
Resíduos por Faixa de Preço	20
6.3 Pressupostos dos Resíduos	21
7. Interpretação dos Resultados	24
7.1 O que o Modelo Final nos Diz	24
Tipo de Alojamento	24
Localização	24
7.2 Análise Crítica do Modelo	24
8. Decisão de Não Alterar o Modelo	25

1. Introdução

Este projeto utiliza dados públicos do **Inside Airbnb** (<https://insideairbnb.com/>) para construir um modelo de regressão capaz de prever o preço por noite de um alojamento na **Tasmânia**, Austrália, com base nas suas características observáveis.

Mais especificamente usa-se o conjunto de dados **listings.csv**, que contém milhares de registos com informações geográficas, preços, o tipo de alojamento, entre outras(...).

1.1 Business Understanding

O mercado de alojamento na Tasmânia é complexo. É fortemente dependente de turismo e como tal é inevitavelmente influenciado por sazonalidade.

É também importante reconhecer que como a Tasmânia é uma ilha, o seu mercado de alojamento vai ter uma distribuição geograficamente polarizada, o que se vai refletir no tipo de alojamento disponível e no seu respectivo preço.

Dito isto cabe-nos criar um modelo robusto que consiga ter em conta estes aspetos.

1.2 Definição do Problema

O desafio central reside na otimização da estratégia de preços: um valor excessivamente elevado pode resultar em baixa taxa de ocupação, enquanto que um valor reduzido representa perda de potencial receita.

Assim, a principal questão deste projeto é:

Quais são os fatores que determinam o preço por noite de um Airbnb na Tasmânia? E é possível prevê-lo com base nas variáveis disponíveis?

2. Data Understanding

2.1 Estrutura do Dataset *listings.csv*

O dataset *listings.csv* consta com **6501 observações**, com **18 variáveis**. A variável alvo identificada é a variável **price**, havendo **835** (12,8%) valores em falta neste campo.

Através de uma breve análise ao dataset conseguimos, de imediato, definir as variáveis potencialmente relevantes para a previsão do preço:

Nome da Variável	Tipo	Justificação
<i>neighbourhood</i>	Categórica	Localização geográfica é fator determinante no preço
<i>room_type</i>	Categórica	Tipo de alojamento (casa inteira, quarto privado ou hotel)
<i>minimum_nights</i>	Numérica	Número de noites mínimas mais longas podem refletir preços mais distantes
<i>number_of_reviews_ltm</i>	Numérica	Atividade recente do alojamento.
<i>availability_365</i>	Numérica	<i>Neighbourhood name</i>
latitude; longitude	Numérica	Localização geográfica mais detalhada que <i>neighbourhood</i>

Tabela 1 : Variáveis com potencial para a previsão de *price*

2.2 Limpeza dos dados

As seguintes colunas foram eliminadas com as respetivas justificações:

Nome da Variável	Justificação
<i>id</i> ; <i>host_id</i>	Identificadores do alojamento não têm valor preditivo
<i>name</i> ; <i>host_name</i>	Texto livre específico demais para ser capturado num modelo
<i>neighbourhood_group</i>	Variável com 100% (6.501) dos seus campos com valores em falta (NA's)
<i>license</i>	Informação burocrática, campo em texto que varia imenso e não afeta o valor do mercado.

<i>last_review</i>	É uma data sem poder preditivo direto dado que a atividade recente já está capturada por <i>number_of_reviews_ltm</i>
<i>calculated_host_listings_count</i>	Correlação próxima de 0 com <i>price</i> e elevada assimetria
<i>Number_of_reviews ; reviews_per_month</i>	Multicolinearidade elevada com <i>number_of_reviews_ltm</i> (>0.68)

Tabela 2 : Variáveis descartadas

Certificamo-nos que nenhuma variável apresentava um **desvio-padrão** igual a **0**, dado que se fosse esse o caso, essa variável não teria valor preditivo.

De seguida, removemos as linhas com “NA” em *price*. Tendo em conta que esta é a nossa variável alvo não podemos trabalhar com valores omissos neste campo. Também alterámos o seu tipo para numérica.

Através da função **summary**, deparámo-nos com o seguinte:

- O valor **máximo** na variável *minimum_nights* era **120**. Considerámos que este valor não representa o mercado de turismo, sendo um **outlier**, logo decidimos filtrar a base de dados para permitir no máximo 30 dias de estadia, dado que acima deste valor, enquadram-se em arrendamentos de longa duração.
- Os valores de *price* acima do **percentil 99** foram **removidos**, eliminando apenas casos claramente díspares.
- A variável *reviews_per_month* apresentava **369 NA's** correspondentes a alojamentos sem qualquer avaliação. Estes foram **imputados** com valor 0, uma vez que a ausência de avaliações é equivalente a um 0 e não a um valor em falta. Esta variável foi posteriormente removida por multicolinearidade.

Por fim, observou-se que após a limpeza dos valores NA's da variável *price*, que a variável *room_type* apresentava o nível “*Shared Room*” com **0** valores. Assim, **descartou-se** esta categoria, ficando o *dataset* com 3 categorias:

- Entire home/apt
- Hotel Room
- Private Room

```

... Entire home/apt · Private room · Hotel room
  ► Levels:
... [1] "Contagem de cada tipo de quarto no df pré limpeza de NA's:"
...
Entire home/apt    Hotel room    Private room    Shared room
          5721              81          698           1
... [1] "Contagem de cada tipo de quarto no df pós limpeza de NA's:"
...
Entire home/apt    Hotel room    Private room
          5019              59          524

```

Figura 1 : Categorias da variável *room_type* antes e após a limpeza de NA's de *price*

Após esta limpeza, o *dataset* ficou com **5.602 observações** e **8 variáveis**.

2.3 Pré-Processamento e Feature Engineering

A variável *price* apresenta forte assimetria à direita (Fig. 2):




Figura 2 : Histograma dos Preços dos Airbnbs na Tasmânia

Para lidar com esta assimetria, criou-se a variável ***log_price* = log(*price*)** que aproxima a distribuição de uma normal, recorrendo ao logaritmo de *price* (Fig. 3).

A transformação foi validada visualmente através de QQ-plots (Fig. 3), onde a versão logarítmica apresenta maior aderência à normalidade.




Figura 3 : QQ-plot referente ao preço antes e depois da transformação logarítmica

A variável *neighbourhood* continha **29 bairros**. Estes foram reduzidos da seguinte maneira:

Bairros com **menos de 2%** das observações foram agrupados na categoria "Outro". Desta maneira, ficamos com uma melhor representação individual, agrupando **13 bairros menores**, evitando instabilidade nos modelos causada por categorias com muito poucas observações. O grupo "Outro" ficou com **935** observações (16,69%) (Tabela 3).

neighbourhood	n	percentagem
<fct>	<int>	<dbl>
Hobart	1067	19.05
Outro	935	16.69
Launceston	587	10.48
Glamorgan/Spring Bay	515	9.19
Kingborough	409	7.30
Clarence	377	6.73
Break O'Day	335	5.98
Huon Valley	216	3.86
West Tamar	184	3.28
Dorset	180	3.21
Sorell	153	2.73
Central Coast	141	2.52
Tasman	141	2.52
Circular Head	131	2.34
Glenorchy	117	2.09
Waratah/Wynyard	114	2.03

Tabela 3 : Valor absoluto e relativo de alojamentos por cidade

3. Estatísticas Descritivas

3.1 Preço por Tipo de Alojamento




Figura 4 : Boxplot dos preços por tipo de alojamento

O *boxplot* da Figura 4, segmentado por tipo de acomodação, demonstra uma escala de preços bem definida: **casas/apartamentos** completos **exibem em média os preços mais** altos, seguidos por quartos de hotel e quartos privados. Esta variação de preços reforça a relevância da variável *room_type* como um fator preditivo.

3.2 Preço por Bairro




Figura 5 : Boxplots dos preços nos 10 bairros mais populares

A análise do preço mediano dos 10 bairros mais populares (Fig. 5) revela uma notável diferença entre as áreas: **Glamorgan/Spring Bay** que **destaca-se com os preços medianos mais altos** (aproximadamente \$250), enquanto **West Tamar** se encontra na outra extremidade (cerca de \$160). Esta variação geográfica indica que *neighbourhood* tem potencial de ser um bom indicador preditivo.

3.3 Variáveis Numéricas

Minimum_nights

A mediana (2.0), com um valor próximo à média (1.8), revelam que a maioria da distribuição dos dados nesta variável encontra-se neste intervalo. No entanto, existem valores elevados ainda considerados dentro dos 30 dias de estadia máxima imposto.

```
minimum_nights
Min.   : 1.000
1st Qu.: 1.000
Median : 2.000
Mean   : 1.823
3rd Qu.: 2.000
Max.   :30.000
```

Number_of_reviews

A maior parte das observações têm poucas *reviews*, enquanto que outras acumulam muitas. A **média superior à mediana** confirma a assimetria.

```
number_of_reviews
Min.   :  0.0
1st Qu.: 14.0
Median : 48.0
Mean   :101.9
3rd Qu.:132.0
Max.   :1248.0
```

4. Análise de correlação e causalidade




Figura 6 : Matriz de Correlação entre as variáveis numéricas

4.1. Redundância nas Variáveis Review (Multicolinearidade)

A correlação entre *number_of_reviews*, *reviews_per_month* e *number_of_reviews_ltm* é altíssima (**0.68**, **0.7** e **0.9**) (Fig. 6). No fundo as três retratam o mesmo: a popularidade de determinado alojamento.

Assim, **a nossa decisão foi manter apenas a *number_of_reviews_ltm* por retratar a popularidade recente**, isto é: um alojamento pode ter muitas reviews, mas todas referentes a períodos muito distantes no passado, e nós queremos saber se um alojamento é popular atualmente, dado que estes podem praticar preços mais elevados devido à maior procura/tendência, em contraste com um alojamento que já fora popular no passado e agora não, terá de baixar o seu preço para recuperar a popularidade.

4.2. Correlação Entre as Variáveis

A correlação negativa entre o número de *reviews* e o preço é consistente com a hipótese de que alojamentos mais baratos têm maior taxa de ocupação e, consequentemente, acumulam mais avaliações.

Já a correlação positiva entre disponibilidade e preço sugere que alojamentos mais caros ficam disponíveis por mais tempo devido a uma menor taxa de ocupação.

É fundamental distinguir correlação de causalidade: o facto de um alojamento **ter mais reviews não provoca diretamente um preço mais baixo**. É mais provável que a causalidade seja inversa: um preço mais baixo gera mais reservas, o que por sua vez, resulta em mais *reviews*.

5. Modelagem

5.1 Divisão em Treino e Teste

O *dataset* foi **dividido aleatoriamente**, de forma estratificada, em **80% treino** e **20% teste** utilizando a *seed* 131651 para garantir reprodutibilidade (Fig. 7). A distribuição de *room_type* manteve-se consistente entre os dois conjuntos:

```

Numero de observacoes no Treino: 4481
Numero de observacoes no Teste: 1121

Distribuicao no Treino:

Entire home/apt      Hotel room      Private room
           89.6              1.0              9.4

Distribuicao no Teste:

Entire home/apt      Hotel room      Private room
           89.7              1.1              9.3

```

Figura 7 : Distribuição dos tipos de alojamento no conjunto de treino e teste

Foram criados seis modelos de regressão, todos treinados nas 4.481 observações do conjunto de treino. A **variável dependente** em todos os modelos é **log_price** (o logaritmo do preço por noite).

5.2 Modelo 1 - Regressão Linear Simples

O Modelo 1 utiliza apenas uma variável preditora e serve como **baseline** para comparação com modelos mais complexos.

Fórmula: $\log_price \sim number_of_reviews_ltm$

```

Residual standard error: 0.4769 on 4479 degrees of freedom
Multiple R-squared:  0.03974,    Adjusted R-squared:  0.03953
F-statistic: 185.4 on 1 and 4479 DF,  p-value: < 2.2e-16

```

Figura 8 : Resultados do Modelo 1 - Regressão Linear Simples

O R^2 de ~4% confirma que uma única variável numérica é insuficiente.

5.3 Modelo 2 - Regressão Linear Múltipla

Este modelo inclui todas as variáveis selecionadas após o pré-processamento, testando o efeito conjunto de métricas no preço, assim como variáveis categóricas: *neighbourhood* e *room_type* que o R converte automaticamente para variáveis dummy.

- Referência **room_type** : Entire Home/apt
- Referência **neighbourhood** : Break O'Day

Fórmula: $\log_price \sim neighbourhood + room_type + minimum_nights + number_of_reviews_ltm + availability_365$

```
Residual standard error: 0.4386 on 4460 degrees of freedom
Multiple R-squared: 0.1912, Adjusted R-squared: 0.1876
F-statistic: 52.73 on 20 and 4460 DF, p-value: < 2.2e-16
```

Figura 9 : Resultados Modelo 2 - Regressão Linear Múltipla

Devido ao extenso output , selecionaremos apenas um exemplo:

room_typePrivate obteve um coeficiente de -0.512, $\exp(-0.512) - 1 = 0.599 - 1 = -0.401$ o que implica que, mantendo as outras variáveis iguais, um quarto privado custa em média **40% menos** do que uma casa/apartamento.

A melhoria de R^2 do Modelo 1 para o Modelo 2 (0.04 para 0.19) demonstra que a inclusão das novas variáveis ajuda o modelo a explicar melhor a variância dos dados.

5.4 Modelo 3 - Regressão Polinomial

O Modelo 3 testa se a relação entre *number_of_reviews_ltm* e o preço tem uma componente não linear.

Selecionou-se esta variável pois é das variáveis que possui maior correlação com o preço e, na matriz de dispersão, o gráfico de *number_of_reviews_ltm* vs *price* mostra que a nuvem de pontos tem uma forma mais aproximada de uma curva, o que pode não ser bem captado por uma linha reta.

Fórmula: $\log_price \sim neighbourhood + room_type + number_of_reviews_ltm + I(number_of_reviews_ltm^2) + minimum_nights + availability_365$.

```
Residual standard error: 0.4364 on 4459 degrees of freedom  
Multiple R-squared: 0.1996, Adjusted R-squared: 0.1959  
F-statistic: 52.96 on 21 and 4459 DF, p-value: < 2.2e-16
```

Figura 10 : Resultados do Modelo 3 - Regressão Polinomial

O Modelo 3 apresenta um R^2 superior ao do Modelo 2 (0.1996 vs 0.1912). No entanto, insere-se multicolinearidade inevitável num modelo polinomial, pois a variável e o seu quadrado são naturalmente correlacionados. Esta melhoria de R^2 é marginal, não justificando a introdução de complexidade adicional ao modelo.

5.5 Modelo 4 - Regressão Não Linear com Log nos preditores

O Modelo 4 introduz não-linearidade através da **transformação logarítmica das variáveis preditoras contínuas**, criando relações log-log com interpretações diretas.

As variáveis *minimum_nights* e *number_of_reviews_ltm* podem assumir o valor zero. O logaritmo de zero é matematicamente indefinido (tende para $-\infty$), pelo que se adiciona 1 para garantir que o cálculo é sempre válido: $\log(0 + 1) = \log(1) = 0$. Para valores grandes, $0 + 1$ é negligenciável e não afeta a interpretação dos coeficientes.

Não foi aplicado o logaritmo à variável *availability_365* dado que esta apresenta uma distribuição mais uniforme e não se observa a assimetria presente nas outras variáveis.

Fórmula: $\log_price \simeq neighbourhood + room_type + \log(minimum_nights + 1) + \log(number_of_reviews_ltm + 1) + availability_365$

```
Residual standard error: 0.4338 on 4460 degrees of freedom  
Multiple R-squared: 0.2088, Adjusted R-squared: 0.2053  
F-statistic: 58.86 on 20 and 4460 DF, p-value: < 2.2e-16
```

Figura 11 : Resultado do Modelo 4 - Regressão Não Linear com Log

Coeficientes relevantes:

- $\log(\text{reviews_ltm} + 1) = -0.109$
- $\log(\text{minimum_nights} + 1) = -0.080$
- $\text{availability_365} = +0.00047$

Os coeficientes têm a seguinte interpretação: como a relação é log-log, um aumento de 1% nas *reviews* recentes implica uma redução de 0.109% no preço; um aumento de 1% no mínimo de noites está associado a uma redução de 0.080% no preço.

Já a *availability_365*: $\exp(0.00047) - 1 = 0.00047$ indica que cada dia adicional de disponibilidade está associado a um aumento de 0.047% no preço, mantendo o bairro, tipo de quarto, mínimo de noites e *reviews* constantes.

Apesar do aumento do R^2 também não ser significativo, esta formulação é totalmente interpretável dado que cada coeficiente tem significado económico direto.

5.6 Modelo 5 - Regressão Linear com Interação

O Modelo 5 introduz termos de interação *neighbourhood * room_type*, testando se o efeito do tipo de alojamento no preço varia consoante o bairro.

Fórmula: $\log_price \sim \text{neighbourhood} * \text{room_type} + \text{minimum_nights} + \text{number_of_reviews_ltm} + \text{availability_365}$

```
Residual standard error: 0.4349 on 4437 degrees of freedom  
Multiple R-squared: 0.2092, Adjusted R-squared: 0.2015  
F-statistic: 27.29 on 43 and 4437 DF, p-value: < 2.2e-16
```

Figura 12 : Resultados Modelo 5 - Regressão Linear com Interação

Os termos de interação são estatisticamente significativos em vários bairros, confirmando que o efeito do tipo de quarto no preço não é uniforme geograficamente.

No entanto, com 48 coeficientes, o modelo é substancialmente mais complexo do que o Modelo 4, o que se refletiu nos critérios AIC e BIC.

5.6 Modelo 6 - Tentativa com Coordenadas Geográficas

Como tentativa extra, adicionou-se latitude e longitude ao Modelo 2 para testar se, dentro de cada bairro, é possível acrescentar poder preditivo.

O resultado foi um R^2 de 0.1915, praticamente idêntico ao Modelo 2.

Concluimos que a variável *neighbourhood* captura adequadamente a variação geográfica ao nível do bairro, tornando as coordenadas redundantes.

5.7 Escolha do Modelo

Após análise comparativa de todos os modelos, foram considerados dois candidatos finais: o **Modelo 4** e o **Modelo 5**.

O Modelo 5 apresenta o melhor R^2 de teste (0.1483) e o menor RMSE (\$115.47). No entanto, a diferença de performance é marginal face ao Modelo 4: RMSE = \$1.05 e MAPE = 0.29%. Valores que não justificam 48 coeficientes face aos 21 do Modelo 4.

Assim, o **Modelo 4 foi seleccionado como modelo final** com base na sua interpretabilidade: tem o melhor AIC (5255) e BIC (5396) de todos os modelos, o maior R^2 ajustado (0.2053) e é mais interpretável que o Modelo 5.

Modelo	R ² Adj.	R ² Teste	RMSE (\$)	MAPE (%)	AIC	BIC
1 - Linear Simples	0.0395	0.0195	121,55	37,43	6085	6104
2 - Linear Múltipla	0.1876	0.1354	116,20	34,65	5354	5495
3 - Polinomial	0.1959	0.1374	116,15	34,67	5309	5456
4 - Não-Linear ★	0.2053	0.1344	116,52	34,74	5255	5396
5 - Interação	0.2015	0.1483	115,47	34,45	5299	5588

Tabela 4 : Comparação da Performance dos 6 Modelos

5.8 Teste de Chow

A análise do gráfico de Valores Reais vs. Previstos indicou que poderia haver um comportamento diferente entre alojamentos baratos e caros. Assim, aplicou-se o **Teste de Chow** (Tabela 5) para verificar se dois modelos separados seriam superiores a um só modelo.




Figura 13 : Possível segundo Modelo de regressão

Parâmetro	Valor
Ponto de corte	Mediana do log_price = 5.29 (\$198/noite)
Alojamentos baratos ($\leq \$198$)	2.276 observações de treino
Alojamentos caros ($> \$198$)	2.205 observações de treino
p-value	0.509
Decisão	Não rejeita H0. Um modelo é suficiente

Tabela 5 : Resultados do Chow Test

O p-value de 0.509 é muito superior a 0.05, logo não existe evidência estatística que justifique-se utilizar dois modelos. A diferença observada nos extremos do gráfico da Figura 13 resulta de variabilidade não explicada nessas zonas, possivelmente devido ao facto de não termos acesso a mais variáveis específicas de cada alojamento.

6. Avaliação de Performance

6.1 Métricas e resultados do Modelo 4 no conjunto de teste

Foram calculadas as seguintes métricas de avaliação no conjunto de teste:

Métrica	Interpretação	Resultados no Conjunto de Teste
R^2	Proporção da variância explicada pelo modelo	0.1344
RMSE (log)	Erro quadrático médio na escala log, penaliza erros grandes	0.4343
MAE (log)	Erro absoluto médio na escala log, mais robusto a outliers	0.3399
RMSE (\$)	Erro médio na escala original	116,52
MAPE (%)	Erro percentual médio	34,74

Tabela 6 : Métricas e Resultados do Modelo 4 no conjunto de Teste

A diferença entre R^2 de treino (0.21) e de teste (0.13) indica algum **overfitting**: o modelo ajusta melhor os dados que viu do que dados novos.

6.2 Análise de Resultados Graficamente




Figura 14 : Valores Reais vs. Previstos por tipo de Alojamento

Real vs Previsto por Tipo de Alojamento

A decomposição por tipo de alojamento revela comportamentos distintos.

Para **Entire home/apt** (90% do *dataset*), a maior densidade dos pontos acompanha razoavelmente a diagonal, revelando que é onde o modelo funciona melhor. Apesar de existirem alguns pontos extremos, estes derivam do modelo não conseguir captar a variabilidade associada a estes alojamentos.

No **Hotel Room**, como há tão poucas observações, torna-se difícil interpretar se o modelo está a ter uma boa performance, ou se estes resultados derivam da variabilidade amostral.

Para **Private room**, encontramos mais pontos à direita da diagonal, indicando que o modelo tende a **subestimar** os quartos privados: prevê preços mais baixos do que os reais.

Resíduo Médio por Bairro (Conjunto de Teste)




Figura 15 : Resíduo Médio por Bairro

Observamos que os **bairros com maior representação na base de dados apresentaram valores de resíduos médios muito próximo a zero**, como Hobart e Glamorgan/Spring Bay. Com mais dados, o modelo detecta melhor as características do preço destes bairros, sendo então capaz de fazer previsões melhores.

O oposto é também esperado: os bairros com menor representação como Glenorchy, Dorset e Central Coast têm maiores resíduos.

Esta relação é uma limitação imposta pela base de dados. Mais dados por bairros implicaria uma maior calibração do modelo, obtendo melhores resultados.

Resíduos por Faixa de Preço




Figura 16 : Boxplot da distribuição dos resíduos por Faixa de Preço do Modelo 4

Este gráfico demonstra que o modelo tende a prever preços próximos da média, tendo uma maior taxa de erro nos extremos:

Faixa	Resíduo Médio	Conclusão
< 100\$	-0.65	Sobrestimação grave
100 a 150\$	-0.40	Sobrestima
150 a 200\$	aprox. 0	Melhor ajuste
200 a 275\$	+0.1	Subestimação baixa
> 275\$	+0.55	Subestimação grave

Tabela 7 : Conclusões dos resíduos de cada faixa de preço

Esta progressão dos resíduos é consistente com o $R^2 = 0.13$ e com o resultado do Chow Test: **maior variabilidade não captada nos extremos**, onde fatores não existentes na base de dados têm maior peso relativo na determinação do preço.

6.3 Pressupostos dos Resíduos

Pressuposto	Teste	Resultado	Decisão
P1 - Média nula	$E(\varepsilon) = 0$	1.01e-17	Verificado
P2 - Homocedasticidade	Breusch-Pagan	p = 0	Violado
P2 - Homocedasticidade	Goldfeld-Quandt	p = 0.734	Verificado
P3 - Independência	Breusch-Godfrey	p = 0.643	Verificado
P4 - Normalidade	Jarque-Bera	p = 0	Violado
P4 - Normalidade	Kolmogorov-Smirnov	p = 1.14e-05	Violado

Tabela 8 : Verificação dos Pressupostos dos resíduos

Para todos os pressupostos, realiza-se um teste de hipóteses em que a hipótese nula, H_0 , indica a validade do pressuposto. Assim, caso o p-value seja > 0.05 , não se rejeita H_0 , logo o pressuposto é verificado:

P1 Média nula: valor de 1.01e-17 é essencialmente zero. Pressuposto **Verificado**.

P2 Homocedasticidade: os dois testes chegam a conclusões diferentes: o Breusch-Pagan (BP) **rejeita** H_0 enquanto o Goldfeld-Quandt (GQ) **verifica** a homocedasticidade.

O teste de BP averigua se a variância dos resíduos pode ser explicada pelas variáveis independentes do modelo.

Se a variância dos erros aumentar (ou diminuir) com os valores previstos ou com qualquer variável independente, rejeita-se H_0 . Como casas mais caras implicam erros maiores, BP rejeitou H_0 .

Já o teste de GQ divide as observações em dois grupos ordenados por uma variável específica e compara as variâncias dos resíduos entre os dois grupos.

Esta divergência sugere que a heterocedasticidade presente nos dados não tem uma estrutura crescente ou decrescente de acordo com uma variável independente, mas está associada à estrutura das variáveis categóricas do modelo (*neighbourhood*

e *room_type*) que criam subgrupos com variâncias distintas entre si, isto é: o bairro A tem uma variância de resíduos pequena mas o bairro B tem uma variância elevada, etc.

P3 Independência: **Verificado** ($p = 0.643$). Não existe autocorrelação estrutural nas variáveis independentes.

P4 Normalidade: Ambos os testes **rejeitam** a normalidade. A causa não são outliers extremos, dado que foi feito um teste de Bonferroni que identificou apenas 1 observação significativa. A verdadeira causa são as **caudas pesadas** da distribuição dos resíduos evidenciadas no QQ-plot.

Gráficos de Resíduos do Modelo 4




Figura 17 : Resíduos do Modelo 4

- **Residuals vs Fitted:** linha relativamente horizontal e centrada em 0. Verificação do pressuposto de linearidade.
- **Q-Q Plot:** normalidade verificada no centro, desvio nas caudas.
- **Scale-Location:** linha muito próxima da horizontal, no entanto revela alguma heterocedasticidade.

- **Residuals vs Leverage:** leverage máximo de aprox. 0.035. Nenhuma observação ultrapassa a Cook's distance.




Figura 18 : Boxplot dos Resíduos do Modelo 4

O boxplot dos resíduos demonstra que a mediana é praticamente zero e a caixa é aproximadamente simétrica em torno de zero.

A assimetria nas caudas demonstra que existem **mais outliers** acima de +1.0 do que abaixo de -1.0. Estes *outliers* correspondem a alojamentos cujo preço real é muito superior ao previsto, com características especiais não representadas nas variáveis disponíveis.

7. Interpretação dos Resultados

7.1 O que o Modelo Final nos Diz

Tipo de Alojamento

O coeficiente de *Private room* (-0.571) indica que, em média e controlando restantes variáveis, este tipo de alojamento **custa aproximadamente 43% menos** ($[exp(-0.571) - 1 \approx 0.43]$) do que uma casa/apartamento inteiro (categoria de referência).

Já o *Hotel room*, com um coeficiente de (-0.14) indica que é **13% mais barato** do que um apartamento inteiro.

Localização

Para esta variável categórica, a referência é *Break O'Day*. É uma região rural com poucos alojamentos mas muito específicos (ecoturismo, natureza), o que eleva os preços para cima e torna-a uma referência de preço elevado.

Glamorgan/Spring Bay é o **único bairro** com um valor positivo (+7.7% mais caro face à referência).

Glenorchy tem o **maior desconto** (-28.2%): é um bairro suburbano, com menor apelo turístico, o que se reflete claramente nos preços.

7.2 Análise Crítica do Modelo

O modelo é totalmente **interpretável**, isto é, cada coeficiente tem um significado direto e independente, o modelo apresenta **algumas limitações**. Apresentou o melhor AIC e BIC de todos os modelos, logo é o mais eficiente dado o número de parâmetros. Apesar de não cumprir com dois pressupostos, o da homocedasticidade: que, consideramos ser consequência da falta de características intrínsecas dos alojamentos na base de dados; e o da normalidade: que segundo o Teorema do

Limite Central, com mais dados, seria verificado, o modelo é considerado aceitável para os dados em questão.

Já as limitações:

Um R^2 de 0.13 no conjunto de teste demonstra que o modelo explica apenas 13% da variação do preço. O modelo sobrestima alojamentos muito baratos (<\$100) e subestima alojamentos muito caros (>\$275) e bairros com poucas observações têm previsões menos precisas, que é uma limitação de representatividade amostral.

8. Decisão de Não Alterar o Modelo

Foram consideradas possíveis alterações ao modelo e *feature engineering*. A decisão foi manter o Modelo 4 sem alterações porque:

Gráfico Real vs Previsto por tipo de alojamento: o erro sistemático nos tipos de alojamentos poderia ser mitigado com termos de interação entre *room_type* e as variáveis numéricas. No entanto, isso aumentaria substancialmente o número de coeficientes e comprometeria a interpretabilidade.

Resíduo médio por bairro: o erro nos bairros é uma consequência direta da falta de dados. A solução seria recolher mais dados.

Resíduos por faixa de preço: Qualquer transformação sem ser o logaritmo perderia interpretabilidade sem ganho preditivo significativo.